

Quantização de LLMs

Hugging Face 🤗 PEFT / QLoRA

Introdução

O que é PEFT?

Parameter-Efficient Fine-Tuning (PEFT) é uma biblioteca do 🤗 Hugging Face, criada para suportar a criação e o ajuste fino de camadas usando adaptadores nos modelos de grande escala (LLMs). É perfeitamente integrada ao “Accelerate”, também do 🤗 Hugging Face, para modelos de grande escala (LLMs) aproveitando-se do “DeepSpeed” e do “Big Model Inference”.

O que é Quantização?

A quantização é uma técnica para reduzir os custos computacionais e de memória na execução de inferência, representando os pesos e ativações com tipos de dados de baixa precisão, como inteiro de 8 bits, em vez do habitual ponto-flutuante de 32 bits.

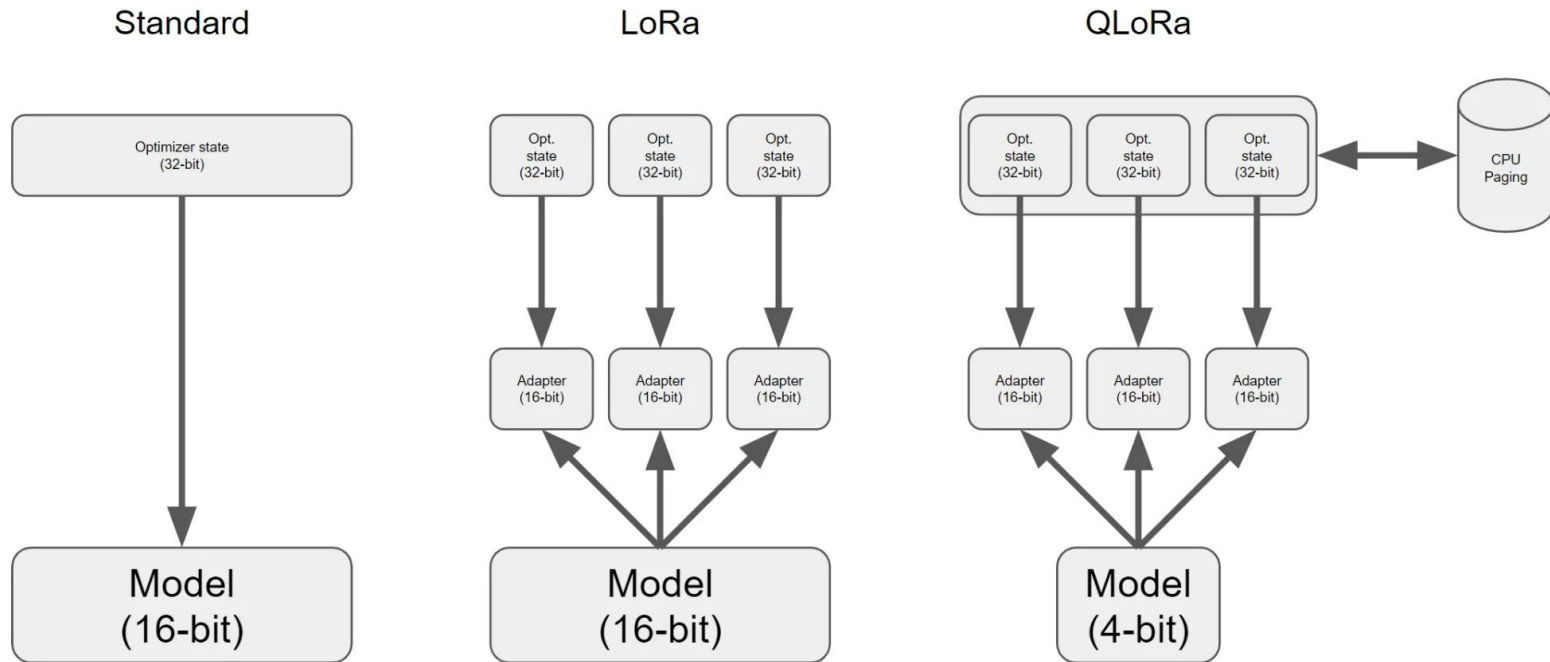
O que é LoRA?

Low-Rank Adaptation of Large Language Models (LoRA) é um método de treinamento que acelera o treinamento de modelos grandes enquanto consome menos memória. São adicionados pares de matrizes de peso do tipo “rank-decomposition” (decomposição de classificação), também chamadas de matrizes de atualização, aos pesos existentes e são treinados apenas os pesos recém-adicionados.

O que é QLoRA? (QLoRA = Quantização + LoRA)

O LoRA adiciona uma pequena quantidade de parâmetros treináveis, ou seja, adaptadores, para cada camada do LLM e congela todos os parâmetros originais. Logo, para ajuste fino, só precisamos atualizar os pesos do adaptador, o que reduz significativamente o espaço ocupado pela memória, e o QLoRA adiciona a isso quantização de 4 bits, quantização dupla e o recurso de Memória Unificada da NVidia para paginação (comunicação performática e confiável CPU ↔ GPU).

Ajuste fino de LLMs com QLoRA



Modelos LLM suportados pelo QLoRA

O QLoRA pode ser usado com qualquer modelo que suporte carregamento acelerado usando a biblioteca “**accelerate**”, ou seja, qualquer modelo que aceite o argumento “**device_map**” ao ser chamado com “**from_pretrained**” deve ser quantizável em 4 bits.

Alguns exemplos de modelos:

'bigbird_pegasus', 'blip_2', '**bloom**', 'bridgetower', 'codegen', 'deit', 'esm', '**gpt2**',
'gpt_bigcode', '**gpt_neo**', '**gpt_neox**', 'gpt_neox_japanese', '**gptj**', 'gptsan_japanese', 'lilt',
'**llama**', 'longformer', '**longt5**', 'luke', 'm2m_100', '**mbart**', 'mega', '**mt5**', 'nllb_moe',
'**open_llama**', '**opt**', 'owlvit', 'plbart', '**roberta**', 'roberta_prelayernorm', 'rwkv',
'switch_transformers', '**t5**', 'vilt', 'vit', 'vit_hybrid', '**whisper**', 'xglm', '**xlm_roberta**', ...

Ajuste fino de um modelo GPTJ-6B usando QLoRA

```
48 # quantization config
49 quant_config = BitsAndBytesConfig(
50     load_in_4bit=True,
51     bnb_4bit_use_double_quant=True,
52     bnb_4bit_quant_type="nf4",
53     bnb_4bit_compute_dtype=torch.bfloat16
54 )
55
56 # model
57 model = AutoModelForCausalLM.from_pretrained(model_name, quantization_config=quant_config, device_map={"":0})
58 model.gradient_checkpointing_enable()
59 model = prepare_model_for_kbit_training(model)
60 lora_args = LoraConfig(
61     r=8,
62     lora_alpha=32,
63     # target_modules=["query_key_value"], # gpt-neox-20b
64     target_modules=["q_proj", "v_proj"], # gpt-j-6b
65     lora_dropout=0.05,
66     bias="none",
67     task_type="CAUSAL_LM"
68 )
69 model = get_peft_model(model, lora_args)
70 model.print_trainable_parameters()
71 # trainable params: 3,670,016 || all params: 3,235,980,512 || trainable%: 0.11341279672082277
```

Consumo de GPU durante o ajuste fino do modelo

*"The GPT-J-6B model is heavy on memory and GPU. You may need a machine with **at least 48 GB RAM**, a **minimum of 12-16 GB GPU RAM for inference**, and about **90 GB GPU RAM for training**."*

- Fonte: <https://www.width.ai/post/gpt-j-vs-gpt-3>

```
152 $ watch -n 3 'nvidia-smi && free -h'
153 +-----+
154 | NVIDIA-SMI 515.105.01    Driver Version: 515.105.01    CUDA Version: 11.7    |
155 |-----+-----+-----+
156 | GPU   Name               Persistence-M| Bus-Id        Disp.A | Volatile Uncorr. ECC |
157 | Fan  Temp  Perf    Pwr:Usage/Cap|      Memory-Usage | GPU-Util  Compute M. |
158 |                                           | MIG M.         |
159 |=====+=====+=====+
160 |    1  NVIDIA GeForce ...   Off      | 00000000:04:00.0 Off  |          N/A         |
161 |100%   89C   P2    166W / 170W | 7439MiB / 12288MiB |      93%      Default |
162 |                                           |          N/A         |
163 |-----+-----+-----+
164 |           |           | total      used      free      shared  buff/cache  available
165 | Mem:      |           | 77Gi      14Gi    23Gi      79Mi     39Gi      62Gi
166 | Swap:     |           | 37Gi       0B     37Gi
```

Resultado do ajuste fino do modelo GPTJ-6B

Adaptador LoRA do modelo:

```
total 15M
-rw-rw-r-- 1 dockeradmin dockeradmin 417 Jul 10 11:44 adapter_config.json
-rw-rw-r-- 1 dockeradmin dockeradmin 15M Jul 10 11:44 adapter_model.bin
-rw-rw-r-- 1 dockeradmin dockeradmin 805 Jul 10 11:44 README.md
```

Resultado do treinamento:

```
44 # Frase original:
45 "I'm selfish, impatient and a little insecure. I make mistakes, I am out of control and at times hard to handle. But if you can't handle me at my
46 worst, then you sure as hell don't deserve me at my best."
47 Marilyn Monroe
48
49 # Saida (todo os 939 steps e 3 epocas):
50 >> I'm selfish, impatient and => I'm selfish, impatient and a little insecure. I make mistakes, I am out of control and at times hard to handle.
51
52 # Saida - modelo original:
53 >> I'm selfish, impatient and => I'm selfish, impatient and a little bit of a control freak. I'm also a mom, a wife, a daughter,
```

Inferência em um modelo GPTJ-6B usando QLoRA

```
17 # quantization config
18 quant_config = BitsAndBytesConfig(
19     load_in_4bit=True,
20     bnb_4bit_use_double_quant=True,
21     bnb_4bit_quant_type="nf4",
22     bnb_4bit_compute_dtype=torch.bfloat16
23 )
24
25 # model
26 model = AutoModelForCausalLM.from_pretrained(model_path, quantization_config=quant_config, device_map={"":0})
27
```

Inferência utilizando carregamento de modelo com adaptador LoRA:

```
12 # quantization config
13 quant_config = BitsAndBytesConfig(
14     load_in_4bit=True,
15     bnb_4bit_use_double_quant=True,
16     bnb_4bit_quant_type="nf4",
17     bnb_4bit_compute_dtype=torch.bfloat16
18 )
19
20 # model com PEFT LoRA
21 config = PeftConfig.from_pretrained(model_path)
22 model = AutoModelForCausalLM.from_pretrained(config.base_model_name_or_path, quantization_config=quant_config, device_map={"":0})
23 model = PeftModel.from_pretrained(model, model_path)
24
```


Consumo de GPU durante a inferência com QLoRA

"To load GPT-J in **float32** one would need at least 2x model size RAM: 1x for initial weights and another 1x to load the checkpoint. So for GPT-J it would take at least **48GB RAM** to just load the model."

- Fonte: https://huggingface.co/docs/transformers/main/model_doc/gptj

```
105 $ nvidia-smi
106 Wed Jul 12 01:57:56 2023
107 +-----+
108 | NVIDIA-SMI 515.105.01    Driver Version: 515.105.01    CUDA Version: 11.7    |
109 |-----+-----+-----+
110 | GPU   Name                               Persistence-M| Bus-Id        Disp.A | Volatile Uncorr. ECC |
111 | Fan   Temp   Perf    Pwr:Usage/Cap|      Memory-Usage | GPU-Util  Compute M. |
112 |                                           | MIG M.         |
113 |=====+=====+=====+
114 |    1  NVIDIA GeForce ...   Off      | 00000000:04:00.0 Off  |             N/A     |
115 |  52%   70C    P2    169W / 170W | 5777MiB / 12288MiB |    93%      Default  |
116 |                                           |             N/A     |
117 +-----+-----+-----+
```

Referências

<https://towardsdatascience.com/qlora-fine-tune-a-large-language-model-on-your-gpu-27bed5a03e2b>

https://huggingface.co/docs/optimum/concept_guides/quantization

<https://github.com/huggingface/peft>

<https://github.com/huggingface/accelerate>

<https://huggingface.co/blog/4bit-transformers-bitsandbytes>

<https://huggingface.co/blog/trl-peft>

<https://huggingface.co/docs/diffusers/training/lora>

https://huggingface.co/docs/transformers/main/model_doc/gptj

<https://developer.nvidia.com/blog/unified-memory-cuda-beginners>

Código utilizado e o modelo GPTJ-6B com o ajuste fino

https://github.com/nlpulse-io/sample_codes/tree/main/fine-tuning/peft_quantization_4bits/gptj-6b

https://huggingface.co/nlpulse/gpt-j-6b-english_quotes

